**附件 6：衍生資料集產出說明文件**

中文專題名稱：AI 金孫 – 不會洩露長輩秘密的生活助理

英文專題名稱：AI Grandchild – A Privacy-Preserving Life Assistant for Older Adults

**一、衍生資料集**

| 資料集名稱與處理狀態 | 公開檢視網址 |
| --- | --- |
| AI 金孫競賽資料集 v3／v4／v5（原始合成來源及 v3 歷史衍生範例） | 資料集檢視 |

本次資料包分開保存原始來源與歷史衍生資料。v3 有 1 份虛構手機環境、3 筆原始任務及 3 筆已處理範例；v4 有 72 份環境、576 筆原始任務；v5 新增 192 份環境、5,184 筆原始任務。v4、v5 尚未經團隊 Privacy Processing System 轉換，不列為新增隱私衍生集。公開包僅含 12 份 CSV／JSON 與 1 份簡單說明，依版本分置三個資料夾，不含研究手機的私人原始匯出。

**二、簡介衍生資料集之產製目的**

本專題延伸原「AI 金孫 – 說到做到的長輩生活助理」的 Gemini Agent、語音互動、行動劇本及手機代操作架構，研究在資料盤點與 Agent 之間加入本機隱私代理層。核心方法為 Task-Centric Minimal Disclosure（任務導向最小揭露）：依當次任務決定必要資料，再交給 AI，而非將整支手機的 Context 一次外傳。

三個主要展示情境為「把照片傳給女兒」、「可疑訊息風險提醒」及「手機狀態救援」；另以撥號、傳訊息、讀通知、提醒、導航及開啟 App 六類任務擴展覆蓋。應用對象為高齡使用者及必要時介入的家人；資料集使用者為 Agent、隱私系統開發者及研究者。手機環境與任務需求分開記錄，以 environment_id 關聯，供後續同任務的揭露與可用性比較。

## 二、產製目的（續）隱私策略與指標

Local-first 設計規劃將 Raw Data 留在本機，先依任務與授權判斷必要資訊，再提供最小 Context。照片分享只揭露目標與照片代碼、選取及確認條件；訊息風險提醒保留判讀必要語意，移除無關識別資訊；狀態救援優先使用網路、音量及勿擾等狀態，不附整份通訊錄或訊息。Gemini 依劇本規劃後，真實收件人等由本機對照還原；取消或高風險時應暫停、澄清或求助家人。以上尚未對 v5 實際轉換。

Privacy 以敏感值外洩、非必要資訊揭露、授權及取消政策違反、跨任務連結風險為評估目標；Fidelity 檢查任務必要條件與引用關係是否保留；Utility 比較操作劇本規劃及實機任務完成情形。原始資料品質與處理後成效分開計算，不能以欄位或位元組縮減率代替匿名性或重識別防護率。

## 三、簡介衍生資料集之 PETs 技術應用

### 1. 技術選擇與目前邊界

v3 已實作規則式必要特徵抽取、候選封包最小化及用途閘門，資料包保留其 3 筆歷史衍生範例。v4、v5 為生成式 AI 協助創作的合成原始資料，未使用真人資料訓練合成模型；SYN_* 是虛構原始識別值，並非對真人資料完成 Tokenization 的結果。

團隊自建 Privacy Processing System 的規則核心為 Privacy Policy Engine，後續依 Task／Required Data／Disclosed Data 對照實作 Data Minimization、Masking、Tokenization／Pseudonymization；位置、時間僅在不影響任務條件時 Generalization（泛化）。代碼對照以 Local Mapping Vault 留在本機，控管存取、任務範圍及生命週期。須記錄規則版本、參數及失敗原因；目前未實作差分隱私，沒有 $\varepsilon$／$\delta$ 保證。

### 2. 原始資料預處理與模板設計

研究手機的 Raw Data 盤點用於了解可得資料類型與揭露風險，公開資料則以虛構環境及任務重建相關樣態。原 v4 的 JSON／CSV 核對發現部分語句與參數、平台版本及導航目錄問題，故保留候選原檔作來源追溯，不直接當作正確答案。v5 另建契約與模板，修正新資料的對照關係，未覆寫舊資料或原有隱私程式。

AI 協助設計 9 類任務、72 個子情境、288 個指令句型，以及 32 個訊息家族與 96 種訊息句型。指令與參數由同一語意定義展開，加入目的地目錄、提醒時間錨點、最新照片及通知的排序條件，並涵蓋取消、缺漏、歧義、未授權及狀態過期等來源條件。

## 3. 生成參數與資料結構

生成器版本為 5.0-raw，固定 seed=20261012。192 份新虛構環境各配置 9 類任務、每類 3 筆，共 5,184 筆，各類 576 筆。AI 協作模板經整合後由 Python 離線確定性組合，不逐筆呼叫 Gemini 或其他 LLM。生成器與 template_catalog.json 由團隊內部留存，不在本次精簡資料包中。

環境 CSV 為 192 列、57 欄，記錄使用者偏好、裝置、聯絡人、App、收藏目的地、權限、電量、網路、音量、畫面、照片中繼資料、訊息、通知、行事曆及定位占位等。任務 CSV 為 5,184 列、46 欄，記錄語句、任務參數、環境參照、授權、確認、取消及來源條件。CSV 為 UTF-8（含 BOM），巢狀陣列以 JSON 文字保存。

六個年齡區間 65-69、70-74、75-79、80-84、85-89、90+ 各 32 份環境；Android API 29-36 各 24 份環境。此配額用於測試覆蓋，不代表真實人口或手機市場分布。STRICT_LOCAL 為 1,776 筆，MINIMIZED_CLOUD 為 3,408 筆；這些模式標籤僅是模擬輸入，不表示已執行隱私處理。

v5 可識別欄位使用 SYN_* 虛構值；訊息網址限定 *.example.invalid；座標 0/0 明確標示為占位，不能用於實際導航；照片只有中繼資料，沒有像素。訊息文字保留為後續處理的原始輸入。所有新增資料均標示 privacy_processing_applied=false。

## 4. 原始產製與後續衍生流程

本輪流程為 AI 情境與語句設計、模板整合、固定種子生成、全量品質驗證、CSV／JSON 輸出及重跑雜湊核對。最新資料位於 03_v5_AI 擴充原始資料；source_raw_v5.json 為完整原始主檔，phone_environments.csv 與 task_requests.csv 是相同資料的兩段表格，不另計筆數。

01 資料夾保存 v3 原始種子及歷史衍生範例，02 保存 v4 候選來源。v3 的 3 筆原始任務已包含在 v4 的 576 筆中；v4 兩份 JSON 共用 72 份環境，不重複計數。v5 另行生成，未混入 v4，且未直接相容舊 v3 驗證器。未來由團隊系統完成轉換，再建立同任務的 Raw、遮蔽／假名化、最小揭露三版本與 derived_tasks.csv、pairs.json、comparison.json；本輪尚無新版輸出。

## 5. 本輪評測方法與實際結果

全量來源品質驗證涵蓋 192 份環境與 5,184 筆任務，檢查型別、鍵值、ID 唯一性、環境及資源引用、時間順序、Android 版本、權限、音量、網路及指令／參數對照。實際完成 247,699 次斷言檢查，發現 0 項錯誤；這是同一批資料的多項工程檢查，不是 247,699 次獨立隱私實驗。

兩份主 CSV 與 JSON 逐列逐欄一致。以相同種子在另一資料夾重新生成，原始 JSON、兩份主 CSV、情境 CSV 與生成報告共 5 個檔案的 SHA-256 皆一致。29 項工程單元測試通過，涵蓋錯誤版本、無效引用、非合成識別值格式注入、語意衝突、時間錯誤、未授權模式及重複 JSON 鍵等負向案例。

原始來源條件包含 304 筆取消、162 筆選取資源缺失、231 筆收件人綁定缺失、27 筆收件人歧義，以及 1,728 筆環境快照超過 300 秒。條件可重疊，不能直接相加；它們不是隱私引擎阻擋數或實機失敗率。300 秒僅為資料分層門檻，尚未驗證為正式政策參數。

上述數值依團隊留存的 validation_report.json、engineering_tests.json 與 reproducibility_report.json 撰寫。公開精簡包只含資料及簡單說明，不附程式、模板、工程報告或競賽文件。模板一致性檢查使用已知創作規格，尚非獨立人工標註或 AI 任務成功率測試。

## 6. 隱私保護力、保真度與實用性驗證界線

本輪確認資料可解析、引用與模板語意一致、生成可重現；尚未量測真人隱私保障、防詐判斷正確率、族群統計保真度或 Android 操作成功率。v5 新增隱私衍生資料為 0 筆，生成期間 LLM API 請求及手機實際動作均為 0 次。這些數值僅描述本輪資料生成與測試，不代表既有 App 的功能測試紀錄，也不能當作 Privacy、Fidelity 或 Utility 成效。

資料包中的隱私衍生結果僅為 derived_tasks_v3_3rows.csv 的 3 筆歷史範例，可與同資料夾的 v3 原始任務比較。這些小樣本結果不適用於 v4 或 v5，也不能證明新增情境的隱私防護與任務可用性。

### 6. 後續正式評估設計（續）

正式評估規劃在相同虛構任務下比較 Raw、遮蔽／假名化與最小揭露三版本。Privacy 檢查直接敏感值、非必要資訊及授權違反，記錄分母與失敗原因，另設連結或指認攻擊對照；Fidelity 檢查必要欄位保留、參數語意及本機引用還原；Utility 以獨立人工標註比較行動劇本，再實機量測任務完成、澄清與安全停止。風險任務轉交家人只提供授權必要摘要。上述正式指標尚無實驗數值。

開發與評估資料須按環境及模板家族隔離，避免相同句型改寫同時出現在兩邊。5,184 筆資料來自有限模板組合，不能視為 5,184 位真人或獨立語意樣本。現有原始資料適合規則開發與條件覆蓋；外推能力仍須以未使用模板、經同意蒐集的真實案例或獨立測試集驗證。

### 7. 生成式 AI 協作揭露

本輪使用 ChatGPT／Codex 協助設計中文子情境、指令句型、訊息家族、生成與驗證程式，以及文件文字。整合時修正語句／參數、導航與時間關聯，加入型別契約、故障注入測試及固定種子重現。每筆紀錄由整理後的模板與程式產生，並非直接複製逐筆自由生成回答；相關模板、原始碼與工程證據由團隊內部留存。

Gemini 是原應用的意圖理解及劇本推理角色，ChatGPT／Codex 則協作本輪原始資料擴充，兩者用途不同。v5 由虛構模板生成，未從實機私人值抽樣；沒有逐筆 LLM 呼叫。資料包不含實際照片、音訊或畫面像素，因此 Gemini 語音、畫面解析與家人通知的外傳路徑仍須另行盤點及驗證，不能由本資料集推論端到端隱私保護已完成。

## 四、結語

本輪完成可重現的 192 份新虛構手機環境與 5,184 筆原始任務，以 72 個子情境支援三個主要展示情境及六類擴充任務。研究特色是在既有生活助理的資料流中，同時考慮語音需求、可用資源、授權、取消與缺漏條件，讓後續隱私系統能說明每項任務原本可取得、實際需要及最後揭露哪些資訊。

資料包清楚區分 v3 歷史衍生基準與 v4、v5 未處理來源，檢視連結列於第一節。下一步須由團隊完成本機隱私代理層、規則轉換、三版本對照及獨立評測，再整合 Gemini Agent 與實機操作。新版隱私處理及量化成效目前尚未完成；是否能降低揭露而保留生活助理功能，須以實際處理及測試結果證明。